

GPS

Météo

Hôtels

S3

ETL

RDS

Plotly

PROJET KAYAK

Pipeline de données : Recommandation de destinations en France

Contexte & Problématique

70%

des utilisateurs veulent
plus d'infos sur les destinations

Le problème

Aucune donnée structurée ne croise **météo + offre hôtelière** pour 35 villes françaises.

Objectif : construire l'infrastructure de données complète → collecter, stocker, transformer et visualiser pour alimenter une future application de recommandation.

Architecture du pipeline :



Collecte des données (3 sources)



Nominatim (GPS)

35 villes françaises

`time.sleep(1)` - rate limit

User-Agent obligatoire



OpenWeatherMap

Prévisions 5 jours / 3h

Score = temp - pluie - humid/10

Clé via Secrets Colab



SerpAPI (Google Hotels)

20 hôtels / ville = 700 total

Booking.com : bloqué
(Cloudflare)

Plan gratuit : 100 req/mois

Data Lake S3 & Data Warehouse RDS

DATA LAKE : AWS S3

*Analogie : l'entrepôt brut à l'arrière
Tout arrive tel quel, rien n'est perdu*

raw/ cities_gps.csv

raw/ weather_raw.csv

raw/ weather_score.csv

raw/ hotels_raw.csv

raw/ hotels_clean.csv

ETL

DATA WAREHOUSE : RDS MySQL

*Analogie : le supermarché bien rangé
Données nettoyées, requêtables en SQL*

cities

35 lignes, GPS

weather

35 lignes, scores météo

hotels

700 lignes, hôtels

Résultats & Visualisations Plotly



Carte 1 : Top 5 Destinations


Taille des bulles = score météo normalisé

Couleur = température (RdYlGn)

Hover = score, temp, pluviométrie

Top 5 au jour de la collecte :

1. La Rochelle
2. Le Havre
3. Lille
4. Bormes-les-Mimosas
5. Toulouse



Carte 2 : Top 20 Hôtels



Filtrés sur les 5 meilleures villes

Triés par overall rating (SerpAPI)

Hover = nom, ville, score, prix/nuit

Données enrichies :

- Nom & coordonnées GPS
- Score (overall_rating)
- Prix par nuit (€)
- Équipements (amenities)



Passage à l'échelle (Big Data)

À cette échelle : Pandas + MySQL suffisent. À l'échelle mondiale (millions d'hôtels, temps réel) :

Besoin	Outil actuel	Outil à l'échelle
Traitement distribué	Pandas	Apache Spark (PySpark)
Data Warehouse analytique	RDS MySQL	Amazon Redshift
Exécution managée	Local / Colab	Amazon EMR
Ingestion temps réel	Batch manuel	Apache Kafka

L'architecture Sources → Lake → ETL → Warehouse → Visu reste identique. Seuls les outils changent.

CONCLUSION

 **Nominatim**

35 villes géocodées

 **OpenWeatherMap**

Score météo sur 5 jours

 **SerpAPI**

700 hôtels collectés

 **AWS S3**

Data Lake : 3 CSV bruts

 **ETL + RDS MySQL**

Data Warehouse : 3 tables

 **Plotly**

2 cartes interactives

Pipeline end-to-end : collecte multi-sources → stockage cloud → ETL → visualization, avec bonnes pratiques de sécurité tout au long.