

Conversion Rate Challenge

Prédire la souscription à une newsletter

284 580 lignes

F1-score · Métrique officielle

Random Forest · GridSearchCV

01 Contexte

02 EDA

03 Modélisation

04 Résultats &
Recommandations

01 · Contexte & Problématique

Contexte

datascienceweekly.org

Newsletter indépendante sur la data science, ouverte à tous. L'équipe souhaite comprendre le comportement des visiteurs pour améliorer son taux de conversion.

284 580 lignes (train)

5 features

Kaggle-style compétition

Objectif

Prédire si un visiteur va s'abonner (variable cible : converted = 0/1)


Métrique officielle : F1-score

Features disponibles

country	Catégorielle
age	Numérique
new_user	Binaire
source	Catégorielle
total_pages_visited	Numérique ★


02 · EDA : Déséquilibre de classes & variable dominante

Distribution de la cible



Seulement 3.2% de conversions → l'Accuracy est inutile, le F1-score est obligatoire


Taux de conversion par pages visitées



16+ pages visitées → 74.3% de conversion. Signal dominant de tout le dataset.


02 · EDA : Profil du convertisseur

Anciens vs Nouveaux visiteurs




Anciens users convertissent 5× plus (7.2% vs 1.4%)

Taux de conversion par pays




Allemagne & UK : marchés prioritaires vs Chine < 0.5%

Taux de conversion par source




La source (SEO/Ads/Direct) a très peu d'impact

03 · Modélisation : Pipeline & Comparaison



Comparaison F1-score




Meilleur modèle : Random Forest GridSearch

F1-score test	0.648
n_estimators	100
max_depth	20
min_samples_leaf	10
class_weight	balanced
Scoring GridSearch	f1
CV folds	3

04 · Résultats & Recommandations métier

Feature importances (Gini — Random Forest)



Recommandations

1

Engagement sur site / levier #1

total_pages_visited représente 76% de l'importance. Améliorer la navigation, recommander des articles connexes, augmenter la qualité du contenu.

2

Fidéliser les anciens utilisateurs

Anciens users : 7.2% vs 1.4% (x5). Retargeting, email de rappel, push notifications.

3

Cibler Allemagne & UK en priorité

DE 6.3%, UK 5.3% => concentrer le budget marketing sur ces marchés. Chine < 0.5% : ROI très faible.

4

Source de trafic : impact marginal

SEO, Ads, Direct convergent tous à ~3.2%. Investir dans la source est secondaire face à l'engagement.

En résumé



Dataset fortement déséquilibré (3.2%) → F1-score comme métrique, `class_weight='balanced'`



Random Forest + GridSearch → F1 test = 0.648, gain de +28% vs baseline LR



`total_pages_visited` : 76% de l'importance Gini, variable dominante sans ambiguïté



Anciens users × 5 de taux de conversion → la fidélisation est le vrai levier