



TNF

THE NORTH FACE

E-commerce : Recommendation & Topic Modeling

Contexte & Objectifs



The North Face

Marque outdoor américaine fondée en 1968. Catalogue de 500 produits avec descriptions détaillées. Objectif : booster les ventes en ligne sur thenorthface.fr.



Problématique

Comment exploiter le texte des fiches produit pour améliorer l'expérience utilisateur et augmenter le taux de conversion ?



3 Livrables

1. Clustering DBSCAN + wordclouds
2. Système de recommandation
3. Topic modeling LSA + wordclouds

Pipeline NLP : Du texte brut au vecteur

01 Nettoyage HTML

Suppression des balises
, , , . Nettoyage des entités HTML et caractères spéciaux. Mise en minuscules.

02 Lemmatisation spacy

Réduction des mots à leur forme de base (running→run). Filtrage : noms, verbes, adjectifs uniquement. Suppression stop words.

03 TF-IDF

500 features max. max_df=0.4 pour éliminer les mots génériques TNF (common thread, recycle...). Unigrams + bigrams.

04 Matrice finale

500 produits × 500 features. Chaque cellule = importance d'un mot pour un produit. Prête pour clustering.

 Décision clé : max_df=0.4, élimine les mots présents dans > 40% des descriptions (sinon : 1 seul mega-cluster)

Partie 1 DBSCAN Clustering

14

Clusters

eps=0.6, min_samples=2

3%

Outliers

16 produits isolés

COS

Distance

cosinus (pas euclidienne)

C0

Sous-vêtements techniques (2)

mesh · support · wicking · stretch

C2

Vestes alpines (6)

dwr · water repellent · heat transfer

C4

Bagagerie (18)

pocket · shoulder strap · durable water

C6

Pulls & Sweaters (2)

knit · sweater · fleece · interior

C8

Odeur & Laine (33)

odor control · gladiodor · natural

C9

T-shirts & Imprimés (61)

tap shoulder · shirt · print · seam

Partie 2 Système de Recommandation

Logique

Deux produits du même cluster DBSCAN sont considérés similaires.

`find_similar_items(item_id)` retourne 5 produits du même cluster.

Gestion des cas outliers (fallback aléatoire).

Exemple réel

id=2 (Active sport boxer briefs)

→ Cluster 0

→ Recommandé : id=3 (Active sport briefs)

Produits similaires cohérents !

Flux de la recommandation



Partie 3 LSA (TruncatedSVD)

15

Topics

n_components=15

38.7%

Variance

expliquée par 15 topics

500

Produits

encodés en topic_encoded_df

T0

T-shirts & Imprimés (74)

shirt · tap shoulder · print

T1

Vêtements imperméables (148)

water · zipper · dwr · repellent

T2

Laine mérinos & Odeur (35)

odor · merino · control · natural

T3

Pantalons & Jeans (40)

button · short · canvas · zip fly

T4

Laine & Entretien (22)

merino wool · wash · flat dry

T6

Vêtements féminins (54)

tencel · bra · coverage · jersey

DBSCAN vs LSA Comparaison

Critère	DBSCAN	LSA (TruncatedSVD)
Type	Clustering non supervisé	Réduction dimensionnelle
Appartenance	1 cluster par produit	Mélange de topics (soft)
Outliers	Oui — label -1	Non — tous assignés
Résultat	14 clusters	15 topics (38.7% variance)
Usage	Recommandation	Restructuration catalogue
Force	Clusters cohérents métier	Topics latents interprétables

Les deux approches sont complémentaires : DBSCAN pour les recommandations produit, LSA pour repenser la navigation du catalogue.

Conclusions & Recommandations

01

Section 'Vous aimeriez aussi'

Déployer `find_similar_items()` sur chaque fiche produit. 14 clusters permettent des recommandations pertinentes par famille.

02

Restructurer le catalogue

15 topics LSA révèlent des catégories émergentes (imperméable, mérinos, femme, bagagerie) plus pertinentes que les catégories actuelles.

03

Stop words domaine-métier

Clé du succès : éliminer les mots génériques TNF (common thread, recycle...) pour que les features soient vraiment discriminantes.

04

Scalabilité

Approche applicable à tout catalogue e-commerce avec descriptions textuelles. Pipeline réutilisable sur tout le catalogue TNF.