

Prédiction des ventes hebdomadaires Walmart

Apprentissage automatique supervisé · Régression linéaire & régularisation

Marine Deldicque · Jedha Fullstack Data Science · Certification CDSD · Python · Scikit-learn

150

observations

8

variables

$R^2=0.90$

test set

01 Contexte & EDA

02 Régression linéaire

03 Régularisation

04 Conclusion

01 · Contexte & Objectifs

Le projet

Le service marketing Walmart demande un modèle ML pour estimer les ventes hebdomadaires par magasin, afin de comprendre l'impact des indicateurs économiques et mieux planifier les campagnes.

Variable cible Weekly_Sales (\$)

Variables éco. Température · Carburant · CPI · Chômage

Catégorielles Magasin (1–20) · Holiday Flag

Période 2010–2012 · 150 semaines

Pipeline du projet

1

EDA & Nettoyage

Outliers, valeurs manquantes, feature engineering Date

2

Prétraitement Pipeline

OHE + StandardScaler + SimpleImputer — sans data leakage

3

Baseline : LinearRegression

Modèle de référence simple et interprétable

4

Régularisation Ridge / Lasso

Réduction de l'overfitting via pénalité L1/L2

5

GridSearchCV sur alpha

9 valeurs × 5 folds = 45 entraînements

02 · EDA & Prétraitement des données

⚠ Problèmes identifiés

- ✗ 14 lignes sans Weekly_Sales → cible manquante
- ✗ 18 dates nulles → feature engineering nécessaire
- ✗ Valeurs manquantes : Température, CPI, Chômage
- ✗ 5 outliers Unemployment $> 3\sigma$ (taux $\sim 14\%$)

✓ Solutions appliquées

- `dropna()` → Suppression des lignes cible=NaN
- `pd.to_datetime()` → Year, Month, Day, DayOfWeek
- `SimpleImputer(median)` → Imputation médiane dans le pipeline
- Règle $\pm 3\sigma$ → Filtre outliers 4 colonnes numériques

Pipeline scikit-learn — anti data leakage



03 · Régression linéaire / baseline

RMSE Train

100 K\$

erreur moyenne

RMSE Test

188 K\$

données inconnues

R² Train

0.978


variance expliquée

R² Test

0.898

variance expliquée

Comparaison Train vs Test



Top coefficients — variables Store

Store_14	+0.9K\$
Store_4	+0.9K\$
Store_20	+0.8K\$
Store_5	-1.1K\$
Store_3	-0.9K\$
Store_16	-0.9K\$

→ Le magasin : variable la plus explicative

⚠ Overfitting léger : R² train (0.978) > R² test (0.898). Écart 0.08, acceptable. Mais 104 lignes pour 29 features → le modèle mémorise les magasins plutôt qu'il n'apprend.

04 · Limites & regard critique sur le modèle

Ratio features/données défavorable

104 lignes d'entraînement pour 29 features (dont 20 colonnes OHE Store). Règle empirique : 10 obs/feature minimum. Ici ~ 3.5 . Le modèle mémorise plutôt qu'il ne généralise.

Test set trop petit pour être fiable

27 lignes en test set. Le $R^2=0.898$ a une forte variance statistique, en re-splitant différemment on obtiendrait probablement des scores très différents.

Le modèle reconnaît plutôt qu'il ne prédit

Les coefficients les plus forts sont tous des identifiants magasin ($\pm 900K\$$). Il dit juste "Store 14 vend toujours beaucoup", pas de vraie relation économique captée.

Ce qu'il faudrait sur un vrai projet

Beaucoup plus de données (dataset Kaggle : 421 570 lignes). Regrouper les magasins par type/taille (3–4 catégories). Tester Random Forest ou Gradient Boosting.

05 · Régularisation — Ridge · Lasso · GridSearchCV

Ridge (L2)

Pénalise proportionnellement tous les coefs. Ici ça écrase les variables Store très informatives → légère dégradation.


Lasso (L1)

Met des coefs exactement à 0 : 1 variable éliminée sur 29. Performances quasi identiques à LinearRegression.

GridSearchCV

9 $\alpha \times 5$ folds = 45 entraînements.
Alpha optimal = 0.01 → confirme que la régularisation forte nuit ici.

Comparatif des modèles



Alpha optimal = 0.01 : la régularisation forte nuit ici. La vraie solution = revoir l'encodage Store.

Modèle	RMSE Test	R ² Test	Note
LinearRegression	188 478 \$	0.8977	Référence
Ridge $\alpha=1$	216 126 \$	0.8655	Sur-régularisé
Lasso $\alpha=1$	188 476 \$	0.8977	1 coef → 0
Ridge $\alpha=0.01^*$	189 230 \$	0.8969	Optimal GS

* trouvé par GridSearchCV — 5-fold cross-validation, 9 valeurs testées

06 · Conclusion & enseignements



Meilleur modèle : LinearRegression / Lasso $\alpha=1$ · RMSE 188K\$ · $R^2=0.90$ sur test set



Variable dominante : l'identifiant magasin explique l'essentiel, pas les indicateurs économiques



Scores à relativiser : R^2 train 0.978 probablement gonflé. 104 lignes pour 29 features. Test set de 27 lignes, peu robuste.



Alpha optimal = 0.01 → la régularisation ne suffit pas. Plus de données + encodage magasin par catégorie seraient nécessaires.