

OncoPrint

Chaque tumeur parle. OncoPrint traduit.

Marine Deldicque · CDSJ Jedha 2026

2,3 millions

de nouveaux cas par an dans le monde : **le cancer du sein est le plus meurtrier chez la femme.**

Chaque tumeur cache des milliers de données génomiques.

Peut-on lire dans les gènes d'une tumeur pour mieux la soigner ?

*Infirmière libérale, j'ai soigné des patientes atteintes de cancer du sein.
Deux patientes, même diagnostic : des traitements radicalement différents.
Cette question m'a conduite vers la data science.*

4

sous-types distincts

1936

variables / tumeur

536

patientes étudiées

Le problème

Le cancer du sein, ce n'est pas une seule maladie.

Il existe 4 sous-types biologiquement distincts. Le traitement dépend du sous-type, pas de la localisation.

Luminal A	Triple Négatif	HER2-enriched	Luminal B
Hormonothérapie	Chimiothérapie	Herceptin	Hormo + anti-HER2

Même organe. Même mot : cancer du sein. Quatre maladies. Quatre traitements.

Aujourd'hui, identifier le bon sous-type repose sur une biopsie et des examens longs et coûteux.
OncoPrint explore si les données génomiques disponibles peuvent accélérer et objectiver cette décision.

Les données : TCGA-BRCA

The Cancer Genome Atlas, programme public du NIH. Profils génomiques complets de patientes atteintes de cancer du sein.

705

patientes initiales

536

après nettoyage

1 936

variables / patiente

4

sous-types cibles

4 types de données combinées pour chaque patiente :

Mutations (249)

Altérations de l'ADN : ex. TP53, PIK3CA

Copy Number (860)

Amplifications et délétions de gènes

RNA-seq (604)

Expression des gènes : ce que la cellule produit

Phospho-protéines (223)

Activation des protéines : ce que la cellule fait réellement

Source : NCI/NIH, données publiques de recherche

Ce qu'on a construit



Données
TCGA-BRCA



Nettoyage
& Préparation



Modèle
XGBoost



API
FastAPI



Dashboard
Streamlit

3 choix techniques qui comptent :

1

SMOTE corrigé : Pour équilibrer les classes rares, on génère des données synthétiques ; mais uniquement sur les données d'entraînement. Sans cette précaution, les résultats semblent meilleurs qu'ils ne le sont.

2

XGBoost : Algorithme testé contre plusieurs modèles, le plus performant sur ce type de données tabulaires avec classes déséquilibrées.

3

Déployé, pas juste un notebook : API + dashboard interactif + rapports générés par IA. Un outil qu'on peut utiliser, pas juste une démonstration.

Résultats : et comment aller plus loin ?

84%

Précision globale

+38% vs aléatoire

76%

F1 Macro

sur 4 sous-types

72%

Validation croisée

stable $\pm 2.5\%$

Luminal A

F1 = 0.89

Bonne performance

HER2-enriched

F1 = 0.83

Aucun cas manqué

Triple Négatif

F1 = 0.82

Bien identifié

Luminal B / HER2+

F1 = 0.50

Sous-type hétérogène — le plus difficile à classer

84%, est-ce suffisant en médecine ?

En médecine, on vise 90% et plus : l'enjeu, c'est la vie des patientes. Pour y arriver :

plus de données (cohortes multi-centres) · ajouter Ki67, stade, âge · valider sur une cohorte externe indépendante

Ce que le modèle a appris

Le modèle identifie les signaux biologiques clés :

Et ces signaux correspondent exactement à ceux que les médecins utilisent depuis des décennies.

Luminal A

Récepteur oestrogène activé

→ cible de l'hormonothérapie

Triple Négatif

Absence de récepteurs

→ aucun traitement ciblé possible

HER2-enriched

HER2 fortement activé

→ cible directe de l'Herceptin

Luminal B

Amplification génomique

→ sous-type agressif connu

Exemple concret

Profil d'entrée :

- Récepteur oestrogène : élevé
- Récepteur progestérone : élevé
- HER2 : absent
- Marqueurs basaux : bas

Prédiction :

Luminal A : 94%

Traitement recommandé :
Hormonothérapie

Et demain ?

Pour la patiente

- Comprendre son sous-type en langage simple
- Accompagnement personnalisé selon son type de cancer et son stade
- Mieux se préparer à la consultation avec son oncologue
- Accès à des ressources adaptées à sa situation

Pour les médecins & la recherche

- Rapport structuré pour l'oncologue
- Étendre à d'autres cancers (poumon, ovaire...)
- Ajouter des données cliniques : stade, Ki67, âge
- Valider sur une cohorte externe : viser 90%+

Pour l'outil

- Infrastructure robuste et pérenne
- Analyse de plusieurs patientes simultanément
- Améliorer la classification Luminal B
- OncoPrint v2.0 : framework générique en oncologie

Peut-on lire dans les gènes d'une tumeur pour mieux la soigner ?

Oui, et voici ce qu'OncoPrint permet de faire :

Identifier le sous-type tumoral :

à partir des données génomiques, avec 84% de précision sur 4 classes

Comprendre pourquoi :

le modèle pointe les biomarqueurs qui comptent, cohérents avec la biologie connue

Estimer le pronostic :

médiane de survie et risque relatif par sous-type (Kaplan-Meier + Cox)

Générer un rapport :

adapté au clinicien, au chercheur ou à la patiente, via IA

Pour aller plus loin : plus de données · Ki67 & stade · cohorte externe · OncoPrint v2.0

Chaque tumeur parle. OncoPrint traduit.